

Chaînes de Markov cachées et application en finance

Maxime Delpéché et Marius Requillart

2026

Définition d'une chaîne de Markov cachée

États cachés. Les états cachés sont modélisés par un processus de Markov $(X_t)_{t \in \mathbb{N}}$ à valeurs dans un ensemble fini

$$E = \{1, \dots, N\}.$$

On note $A = (a_{ij})$ la matrice de transition, avec

$$a_{ij} = \mathbb{P}(X_{t+1} = j \mid X_t = i).$$

Observations. Les observations sont modélisées par un processus $(Y_t)_{t \in \mathbb{N}}$ à valeurs dans un ensemble O . Conditionnellement aux états cachés :

$$\mathbb{P}(Y_t = y \mid X_t = i) = b_i(y),$$

où $B = (b_i(y))$ est la matrice, ou famille, d'émission.

Modèle HMM. Un modèle de chaîne de Markov cachée est défini par le triplet

$$(A, B, \pi),$$

où A est la matrice de transition, B la loi d'émission et π la distribution initiale.

Exemple global d'une chaîne de Markov cachée


$$E = \{C, V\}, \quad \pi_0 = (0.5, 0.5)$$

$$A = \begin{pmatrix} 0.9 & 0.1 \\ 0.2 & 0.8 \end{pmatrix}$$

$$a_{ij} = \mathbb{P}(X_{t+1} = j \mid X_t = i)$$

$$B = \begin{cases} \mathcal{L}(Y_t \mid X_t = C) \sim \mathcal{N}(\mu_C, \sigma_C^2), \\ \mathcal{L}(Y_t \mid X_t = V) \sim \mathcal{N}(\mu_V, \sigma_V^2). \end{cases}$$

Structure du modèle HMM



Les états cachés évoluent selon A , et chaque observation est générée conditionnellement à l'état courant.

Les observations ne sont pas markoviennes

Propriété. Dans un HMM non dégénéré, le processus d'observations $(Y_t)_t$ n'est pas un processus de Markov, même si les états cachés $(X_t)_t$ le sont.

On a :

$$\mathbb{P}(Y_{n+1} \mid Y_1, \dots, Y_n) = \sum_{i=1}^K \mathbb{P}(Y_{n+1} \mid X_{n+1} = i) \mathbb{P}(X_{n+1} = i \mid Y_1, \dots, Y_n)$$

Or,

$$\mathbb{P}(X_{n+1} = i \mid Y_1, \dots, Y_n) = \sum_{j=1}^K \mathbb{P}(X_{n+1} = i, X_n = j \mid Y_1, \dots, Y_n)$$

Et

$$\mathbb{P}(X_{n+1} = i \mid Y_1, \dots, Y_n) = \sum_{j=1}^K a_{ji} \mathbb{P}(X_n = j \mid Y_1, \dots, Y_n)$$

Dépendance au passé observé

$$\mathbb{P}(X_n = j \mid Y_1, \dots, Y_n) = \frac{\mathbb{P}(Y_n \mid X_n = j, Y_1, \dots, Y_{n-1})\mathbb{P}(X_n = j, Y_1, \dots, Y_{n-1})}{\mathbb{P}(Y_1, \dots, Y_n)}$$

$$\mathbb{P}(X_n = j \mid Y_1, \dots, Y_n) = \frac{\mathbb{P}(Y_n \mid X_n = j)\mathbb{P}(X_n = j \mid Y_1, \dots, Y_{n-1})}{\mathbb{P}(Y_n \mid Y_1, \dots, Y_{n-1})}.$$

$$\begin{aligned}\mathbb{P}(Y_{n+1} \mid Y_1, \dots, Y_n) &= \sum_{i=1}^K \sum_{j=1}^K a_{ji} \frac{\mathbb{P}(Y_{n+1} \mid X_{n+1} = i)\mathbb{P}(Y_n \mid X_n = j)}{\mathbb{P}(Y_n \mid Y_1, \dots, Y_{n-1})} \\ &\quad \times \mathbb{P}(X_n = j \mid Y_1, \dots, Y_{n-1}).\end{aligned}$$

Ainsi, on remarque bien que

$$\mathbb{P}(Y_{n+1} \mid Y_1, \dots, Y_n) \neq \mathbb{P}(Y_{n+1} \mid Y_n).$$

Algorithme Forward

La vraisemblance de la séquence observée est :

$$\mathbb{P}(Y) = \sum_X \mathbb{P}(Y, X) = \sum_X \mathbb{P}(Y | X) \mathbb{P}(X).$$

Principe

On définit

$$\alpha_t(i) = \mathbb{P}(y_1, \dots, y_t, X_t = i).$$

Initialisation

$$\alpha_1(i) = \pi_i b_i(y_1), \quad i = 1, \dots, N.$$

Récursion

$$\alpha_t(j) = b_j(y_t) \sum_{i=1}^N \alpha_{t-1}(i) a_{ij}, \quad t = 2, \dots, T.$$

Terminaison


$$\mathbb{P}(Y) = \sum_{i=1}^N \alpha_T(i).$$

Algorithme de Viterbi

On estime le chemin le plus probable avec :

$$\delta_t(i) = \max_{x_1, \dots, x_{t-1}} \mathbb{P}(X_1, \dots, X_t = i, y_1, \dots, y_t \mid \lambda)$$

$$\delta_{t+1}(j) = \left[\max_{1 \leq i \leq N} \delta_t(i) a_{ij} \right] b_j(y_{t+1})$$



Algorithme de Baum–Welch : étape E

Baum–Welch est un algorithme EM : à partir d'un modèle courant

$$\lambda^{(k)} = (\pi^{(k)}, A^{(k)}, B^{(k)}),$$

on estime les états cachés, puis on met à jour les paramètres.

Probabilité d'être dans l'état i au temps t :

$$\gamma_t(i) = \mathbb{P}(X_t = i \mid Y, \lambda^{(k)}) = \frac{\alpha_t(i)\beta_t(i)}{\sum_{\ell=1}^N \alpha_t(\ell)\beta_t(\ell)}.$$

Probabilité de transition $i \rightarrow j$ entre t et $t+1$:

$$\xi_t(i, j) = \mathbb{P}(X_t = i, X_{t+1} = j \mid Y, \lambda^{(k)}).$$

$$\xi_t(i, j) = \frac{\alpha_t(i)a_{ij}^{(k)}b_j^{(k)}(y_{t+1})\beta_{t+1}(j)}{\sum_{r=1}^N \sum_{s=1}^N \alpha_t(r)a_{rs}^{(k)}b_s^{(k)}(y_{t+1})\beta_{t+1}(s)}.$$

$$\gamma_t(i) \quad \text{et} \quad \xi_t(i, j)$$

donnent les nombres moyens de visites des états et de transitions.

Algorithme de Baum–Welch : étape M

Une fois $\gamma_t(i)$ et $\xi_t(i, j)$ calculés, on met à jour les paramètres.

Distribution initiale :

$$\pi_i^{(k+1)} = \gamma_1(i).$$

Matrice de transition :

$$a_{ij}^{(k+1)} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)}.$$

Émissions discrètes :

$$b_j^{(k+1)}(y) = \frac{\sum_{t=1}^T \gamma_t(j) \mathbf{1}_{\{Y_t=y\}}}{\sum_{t=1}^T \gamma_t(j)}.$$

Émissions gaussiennes :

$$\mu_j^{(k+1)} = \frac{\sum_{t=1}^T \gamma_t(j) Y_t}{\sum_{t=1}^T \gamma_t(j)}, \quad (\sigma_j^2)^{(k+1)} = \frac{\sum_{t=1}^T \gamma_t(j) (Y_t - \mu_j^{(k+1)})^2}{\sum_{t=1}^T \gamma_t(j)}.$$

On répète ces étapes jusqu'à stabilisation de

$$\ell^{(k)} = \log \mathbb{P}(Y \mid \lambda^{(k)}).$$

Évaluation de l'algorithme Forward

L'algorithme Forward permet d'évaluer la qualité du modèle à partir de la vraisemblance :

$$\ell(\lambda) = \log \mathbb{P}(Y_{1:T} \mid \lambda).$$

Critères utilisés :

- **Log-vraisemblance moyenne**

$$\bar{\ell}(\lambda) = \frac{1}{T} \ell(\lambda)$$

- **Critères pénalisés**

$$AIC = -2\ell(\lambda) + 2p, \quad BIC = -2\ell(\lambda) + p \log(T)$$

- **Validation hors échantillon**

$$NLPD_{\text{test}} = -\frac{1}{T_{\text{test}}} \log \mathbb{P}(Y_{\text{test}} \mid \hat{\lambda}_{\text{train}})$$

Une bonne performance Forward correspond à une log-vraisemblance élevée, des critères AIC/BIC faibles, et une NLPD stable sur les données de test.

Évaluation de l'algorithme de Viterbi

Viterbi estime la trajectoire cachée la plus probable :

$$\hat{X}_{1:T}^V \in \arg \max_{x_{1:T}} \mathbb{P}(X_{1:T} = x_{1:T} \mid Y_{1:T}, \hat{\lambda}).$$

Critères utilisés :

- **Interprétation des régimes** : vérifier si les états détectés correspondent à des comportements observables distincts.
- **Persistance des régimes** :

$$\text{taux de changement} = \frac{1}{T-1} \sum_{t=1}^{T-1} \mathbf{1}_{\{\hat{X}_t^V \neq \hat{X}_{t+1}^V\}}.$$

- **Comparaison avec le posterior decoding et le decoding local**

$$D_{VP} = \frac{1}{T} \sum_{t=1}^T \mathbf{1}_{\{\hat{X}_t^V \neq \hat{X}_t^P\}}.$$

Un bon décodage est cohérent temporellement, interprétable, et proche du posterior decoding lorsque l'incertitude sur les états est faible.

Évaluation de l'algorithme de Baum–Welch

Baum–Welch estime les paramètres du modèle :

$$\hat{\lambda} = (\hat{\pi}, \hat{A}, \hat{B}) \in \arg \max_{\lambda} \mathbb{P}(Y_{1:T} \mid \lambda).$$

Critères utilisés :

- **Convergence de la log-vraisemblance**

$$\Delta_k = \ell^{(k)} - \ell^{(k-1)}, \quad r_k = \frac{\Delta_k}{1 + |\ell^{(k-1)}|}.$$

- **Stabilité selon l'initialisation**

$$D_A = \frac{1}{N} \sum_i \frac{1}{2} \sum_j |\hat{a}_{ij}^{(a)} - \hat{a}_{ij}^{(b)}|.$$

- **Interprétation des régimes** : les états estimés doivent correspondre à des comportements distincts.
- **Validation hors échantillon**

$$NLPD_{\text{test}} = -\frac{1}{T_{\text{test}}} \log \mathbb{P}(Y_{\text{test}} \mid \hat{\lambda}_{\text{train}}).$$

Simulation d'une chaîne de Markov cachée

On simule un HMM à trois états cachés :

$$S = \{\text{soleil, nuageux, pluie}\}$$

et deux observations possibles :

$$O = \{\text{parapluie, pas parapluie}\}.$$

$$\pi = (0.5 \quad 0.3 \quad 0.2)$$

$$A = \begin{pmatrix} 0.7 & 0.295 & 0.005 \\ 0.3 & 0.4 & 0.3 \\ 0.005 & 0.395 & 0.6 \end{pmatrix} \quad B = \begin{pmatrix} 0.1 & 0.9 \\ 0.4 & 0.6 \\ 0.9 & 0.1 \end{pmatrix}$$


La trajectoire simulée contient $T = 1001$ observations, avec les vrais états cachés connus.

Résultats bruts des algorithmes sur la simulation

Forward

$$\log \mathbb{P}(Y_{1:T} \mid \lambda) = -639.814329.$$


Viterbi



Baum–Welch

$$\hat{A} = \begin{pmatrix} 0.7026 & 0.2956 & 0.0018 \\ 0.2720 & 0.5963 & 0.1316 \\ 0.1804 & 0.2172 & 0.6024 \end{pmatrix} \quad \hat{B} = \begin{pmatrix} 0.1070 & 0.8930 \\ 0.5702 & 0.4298 \\ 0.9895 & 0.0105 \end{pmatrix}$$

Analyse Forward sur la simulation



Comparaison de modèles

Modèle	log-vrais.	log-vrais./obs.	NLPD	AIC	BIC
Simulation	-639.814329	-0.639175	0.639175	1301.628658	1355.624961
Transitions unif.	-689.395632	-0.688707	0.688707	1400.791264	1454.787566
Émissions unif.	-693.840328	-0.693147	0.693147	1409.680655	1463.676958
Modèle unif.	-693.840328	-0.693147	0.693147	1409.680655	1463.676958

Validation hors échantillon

Segment	T	log-vrais.	log-vrais./obs.	NLPD
Apprentissage	800	-511.319586	-0.639149	0.639149
Test cond.	201	-128.494743	-0.639277	0.639277
Test indép.	201	-128.462530	-0.639117	0.639117


Analyse Viterbi sur la simulation

Persistence des séquences

Séquence	Chang.	Taux	Runs	Moy.	Max
Viterbi	326	32.60%	327	3.06	28
Posterior decoding	390	39.00%	391	2.56	21
Décodage local	358	35.80%	359	2.79	23





Viterbi vs posterior decoding

Critère	Valeur
D_{VP}	8.39%
Désaccord Viterbi / décodage local	24.48%
Proba post. moyenne Viterbi	66.04%
Proba post. médiane Viterbi	67.99%
Marge post. moyenne	38.33%
Marge post. médiane	42.12%



Comparaison visuelle entre Viterbi, posterior decoding et décodage local.

Analyse Baum–Welch sur la simulation



Application au VIX


On applique le HMM au VIX en utilisant trois variables observées :

$$R_t = \log(V_t) - \log(V_{t-1}), \quad \sigma_t^{(5)} = \text{std}(R_{t-4}, \dots, R_t), \quad \sigma_t^{(20)} = \text{std}(R_{t-19}, \dots, R_t).$$

Le rendement logarithmique R_t décrit les variations journalières du VIX, la volatilité courte $\sigma_t^{(5)}$ capte les mouvements récents, et la volatilité longue $\sigma_t^{(20)}$ décrit une dynamique plus persistante.

Statistiques moyennes obtenues pour les trois régimes

Régime	VIX moyen	R_t moyen	$\sigma_t^{(20)}$ moyenne	Nombre d'observations
Calme	16.3809	0.0007	0.0466	2364
Intermédiaire	20.0225	-0.0021	0.0719	1751
Crise	23.6703	0.0018	0.1134	1003




Analyse Baum–Welch sur le VIX

Convergence

Critère	Valeur
Nombre d'observations T	5118
Meilleure initialisation	10
Nombre d'itérations	36
Log-vraisemblance finale	-14300.087178
Log-vraisemblance moyenne	-2.794077
Gain final / observation	9.728857×10^{-11}
Gain relatif final	3.481714×10^{-11}
Baisses détectées	0

Comparaison des initialisations



Validation hors échantillon

Segment	T	Log-vraisemblance	NLPD
Apprentissage	4094	-11536.441391	2.817890
Test conditionnel	1024	-2774.008272	2.708992
Test indépendant	1024	-2782.320895	2.717110