

Chaîne de Markov cachées et application en finance

Sous la supervision de *Joseph Rynkiewicz et Jean-Marc Bardet*.

Par Marius Requillart et Maxime Delpech.

2025–2026

SOMMAIRE

I) Introduction

II) Définition et propriétés

2.1) Définitions

2.1.1) Variables aléatoires observables et cachées.

2.1.2) Propriétés.

2.2) Définition chaîne de Markov cachée.

2.2.1) Variables aléatoires observables et cachées.

2.2.2) Lois jointes et vraisemblance.

2.2.3) Exemple global d'une chaîne de Markov cachée.

2.2.4) Remarques sur les observations.

III) Trois grandes problématiques des HMM

1) Estimation de la vraisemblance et forward algorithm.

2) Decodding et Viterbi algorithm.

c) Learning et Baum–Welch algorithm.

IV) Application aux séries temporelles financières

1 Introduction

2 Définitions et propriétés

Toutes les variables aléatoires de ce travail sont définies sur l'espace probabilisé $(\Omega, \mathcal{F}, \mathbb{P})$.

2.1 Définitions et propriétés d'un chaîne de Markov

2.1.1 Définition

Définition d'une chaîne de Markov :

Soit E un ensemble fini ou dénombrable, appelé *espace d'états*. Soit $(X_n)_{n \geq 0}$ un *processus* à valeur dans E . On dit que $(X_n)_{n \geq 0}$ est une *chaîne de Markov* d'ordre 1, si :

Pour tout $n \geq 0$, pour tout $y \in E$, pour tout $x_0, \dots, x_{n-1}, x \in E$ tel que $\mathbb{P}(X_0 = x_0, \dots, X_{n-1} = x_{n-1}, X_n = x) > 0$, on a :

$$\mathbb{P}(X_{n+1} = y \mid X_n = x_n, X_{n-1} = x_{n-1}, \dots, X_0 = x_0) = \mathbb{P}(X_{n+1} = x_{n+1} \mid X_n = x_n)$$

On pose π_0 la distribution initiale, i.e., la loi de X_0 .

De plus, s'il existe $P : E \times E \rightarrow [0, 1]$ tel que $(x, y) \mapsto P(x, y) = \mathbb{P}(X_{n+1} = y \mid X_n = x_n)$, pour tout $n \geq 0$, pour tout $x, y \in E$ tel que $\mathbb{P}(X_n = x_n) > 0$. On dit alors que $(X_n)_{n \geq 0}$ est une chaîne de Markov d'ordre 1 *homogène*. Dans ce cas, P est appelé *matrice de transition* du processus $(X_n)_{n \geq 0}$, avec $P(x, y) > 0$ et $\sum_{y \in E} P(x, y) = 1$, pour tout $x, y \in E$.

Dans ce travail, nous ne considérerons qu'uniquement les chaînes de Markov d'ordre 1 homogènes, c'est pourquoi nous les appellerons juste chaînes de Markov.

2.1.2 Propriétés

• **Équation de Chapman-Kolmogorov :**

Soit $(X_n)_{n \geq 0}$ une chaîne de Markov de matrice de transition P et de distribution initiale π_0 . On a, Pour tout $n \geq 0$, pour tout $x_0, \dots, x_n \in E$,

$$\mathbb{P}(X_0 = x_0, \dots, X_n = x_n) = \pi_0(x_0) \mathbb{P}(x_0, x_1) \dots \mathbb{P}(x_{n-1}, x_n)$$

i.e. la loi d'une chaîne de Markov est entièrement caractérisée par sa distribution initiale et sa matrice de transition.

• **Propriété de Markov :**

Soit $n \geq 0$, π_0 une mesure de probabilité sur E et $x \in E$ tel que $\mathbb{P}_{\pi_0}(X_n = x) > 0$.

Alors, pour tout $A \in E^n$, $B \in E^m$, $m \geq 0$, on a :

$$\mathbb{P}_{\pi_0}((X_0, \dots, X_{n-1}) \in A, (X_{n+1}, \dots, X_{n+m}) \in B \mid X_n = x) = \mathbb{P}_{\pi_0}((X_0, \dots, X_{n-1}) \in A \mid X_n = x) \\ \times \mathbb{P}_{\pi_0}((X_{n+1}, \dots, X_{n+m}) \in B \mid X_n = x).$$

i.e. le passé et le futur d'un moment n d'une chaîne de Markov sont indépendants entre eux.

• **Quelques propriétés utiles :**

2.2 Définition d'une chaîne de Markov cachée

Les chaîne de Markov cachées (HMM) sont des modèles statistique utilisées dans un situation où on a des états latent qui ne sont pas directement observable. Les données observables sont générées par ces état suivant une loi de probabilité conditionnelle.

2.2.1 Variables aléatoires observables et cachées

Définition. Les états cachés sont modélisés par un processus de Markov $(X_t)_{t \in \mathbb{N}}$ à valeurs dans un ensemble fini $Q = \{1, \dots, N\}$. On note $A = (a_{ij})$ la matrice de transition définie par :

$$a_{ij} = \mathbb{P}(X_{t+1} = j \mid X_t = i).$$

Définition. Les observations sont modélisées par un processus $(Y_t)_{t \in \mathbb{N}}$ à valeurs dans un ensemble O . Conditionnellement aux états cachés, les variables (Y_t) sont indépendantes et vérifient :

$$\mathbb{P}(Y_t = y \mid X_t = i) = b_i(y),$$

où $B = (b_i(y))$ est la matrice (ou famille) d'émission.

Définition. Un modèle de chaîne de Markov cachée est défini par le triplet (A, B, π) où :

- A est la matrice de transition des états cachés,
- B est la loi d'émission des observations,
- π est la distribution initiale, avec $\pi_i = \mathbb{P}(X_1 = i)$.

2.2.2 Loi jointes et vraisemblance

Propriété : Soit $X = (X_1, \dots, X_T)$ la séquence d'états cachés et $Y = (Y_1, \dots, Y_T)$ la séquence d'observations, la loi des observations conditionnellement à la séquence d'états cachés est :

$$\mathbb{P}(Y | X) = \prod_{t=1}^T \mathbb{P}(Y_t | X_t)$$

Preuve :

$$\mathbb{P}(Y | X) = \prod_{t=1}^T \mathbb{P}(Y_t | X_1, \dots, X_T, Y_1, \dots, Y_{t-1}) = \prod_{t=1}^T \mathbb{P}(Y_t | X_t)$$

Propriété : Soit $X = (X_1, \dots, X_T)$ la séquence d'états cachés et $Y = (Y_1, \dots, Y_T)$ la séquence d'observations, la loi jointes des observations et des états cachés est donnée par :

$$\mathbb{P}(Y, X) = \pi_{X_1} \prod_{t=2}^T \mathbb{P}(X_t | X_{t-1}) \prod_{t=1}^T \mathbb{P}(Y_t | X_t)$$

Preuve :

$$\begin{aligned} \mathbb{P}(X, Y) &= \mathbb{P}(X_1, Y_1) \prod_{t=2}^T \mathbb{P}(X_t, Y_t | X_1, \dots, X_{t-1}, Y_1, \dots, Y_{t-2}) \\ &= \mathbb{P}(X_1) \mathbb{P}(Y_1 | X_1) \prod_{t=2}^T \mathbb{P}(X_t | X_1, \dots, X_{t-1}, Y_1, \dots, Y_{t-2}) \mathbb{P}(Y_t | X_1, \dots, X_{t-1}, Y_1, \dots, Y_{t-2}) \\ &= \mathbb{P}(X_1) \mathbb{P}(Y_1 | X_1) \prod_{t=2}^T \mathbb{P}(X_t | X_{t-1}) \mathbb{P}(Y_t | X_t) \\ &= \mathbb{P}(X_1) \prod_{t=2}^T \mathbb{P}(X_t | X_{t-1}) \prod_{t=1}^T \mathbb{P}(Y_t | X_t) \\ &= \pi_{X_1} \prod_{t=2}^T \mathbb{P}(X_t | X_{t-1}) \prod_{t=1}^T \mathbb{P}(Y_t | X_t) \end{aligned}$$

Remarque : La loi des observations à chaque instant t est dépend de l'état caché à cet instant et pas des états d'avant.

Exemple : Soit un modèle de chaîne de Markov cachée avec deux états A et B . En supposant que les observation sont gaussienne conditionnellement à l'état caché, on a :

$$\mathbb{P}(Y_t | X_t = A) \sim \mathcal{N}(\mu_A, \sigma_A^2)$$

$$\mathbb{P}(Y_t \mid X_t = B) \sim \mathcal{N}(\mu_B, \sigma_B^2)$$

Remarque : X_t agit comme un selecteur de distribution pour Y_t .

2.2.3 Exemple de globale d'une chaîne de Markov cachée

Prenons un exemple simple d'une chaîne de Markov cachée avec deux états C et V (pour "calme" et "volatile") et des observations gaussiennes conditionnelles à ces états.

Soit $E = \{C, V\}$ l'ensemble d'états, on note π la distribution initiale, par exemple $\pi_0 = (0.5, 0.5)$, indiquant que le processus commence avec une probabilité égale dans les états C et V .

La matrice de transition A peut être définie comme suit :

$$A = \begin{pmatrix} 0.9 & 0.1 \\ 0.2 & 0.8 \end{pmatrix}$$

Avec, $a_{ij} = \mathbb{P}(X_{t+1} = j \mid X_t = i)$.

La matrice d'émission B peut être définie par les distributions gaussiennes conditionnelles à chaque état :

$$B = \begin{cases} \mathbb{P}(Y_t \mid X_t = C) \sim \mathcal{N}(\mu_C, \sigma_C^2) \\ \mathbb{P}(Y_t \mid X_t = V) \sim \mathcal{N}(\mu_V, \sigma_V^2) \end{cases}$$

NB : La matrice de transition A n'est pas connue dans la plupart des applications, elle doit être estimée à partir des données d'observations. Par exemple avec l'algorithme de Baum-Welch que nous verrons plus tard.




FIGURE 1 – Modèle de Markov caché (HMM)

2.2.4 Remarques sur les observations

Propriété : La probabilité totale des observation Y_T est donnée par :

$$\mathbb{P}(Y) = \sum_X \mathbb{P}(Y, X) = \sum \mathbb{P}(Y | X) \mathbb{P}(X)$$

Propriété : Dans un HMM les observations (Y_t) n'est pas un processus de Markov, même si les états cachés (X_t) le sont.

Preuve :

Si le processus d'observations (Y_t) était markovien. Alors on aurait

$$\mathbb{P}(Y_{n+1} | Y_1, \dots, Y_n) = \mathbb{P}(Y_{n+1} | Y_n).$$

Or, pour K états cachés, on a

$$\begin{aligned} \mathbb{P}(Y_{n+1} | Y_1, \dots, Y_n) &= \sum_{i=1}^K \mathbb{P}(Y_{n+1}, X_{n+1} = i | Y_1, \dots, Y_n) \\ &= \sum_{i=1}^K \mathbb{P}(Y_{n+1} | X_{n+1} = i, Y_1, \dots, Y_n) \mathbb{P}(X_{n+1} = i | Y_1, \dots, Y_n) \\ &= \sum_{i=1}^K \mathbb{P}(Y_{n+1} | X_{n+1} = i) \mathbb{P}(X_{n+1} = i | Y_1, \dots, Y_n). \end{aligned}$$

Ainsi, le terme

$$\mathbb{P}(X_{n+1} = i | Y_1, \dots, Y_n)$$

dépend en général de tout le passé observé $(Y_1, \dots, Y_n)$, et pas seulement de Y_n .

Donc, en général,

$$\mathbb{P}(Y_{n+1} | Y_1, \dots, Y_n) \neq \mathbb{P}(Y_{n+1} | Y_n),$$

ce qui montre que le processus d'observations (Y_t) n'est pas markovien.

3 Trois grandes problématiques des HMM

3.1 Estimation de la vraisemblance et forward algorithm

Problématique : Comment calculer efficacement la vraisemblance $\mathbb{P}(Y)$ d'une séquence d'observations Y donnée un modèle de HMM (A, B, π) ?

On suppose que la matrice de transition A , la matrice d'émission B ainsi que la distribution initiale π sont connues.

On sait que la vraisemblance de Y est donnée par :

$$\mathbb{P}(Y) = \sum_X \mathbb{P}(Y, X) = \sum_X \mathbb{P}(Y | X) \mathbb{P}(X).$$

Cependant, pour N états cachés et une séquence d'observations de longueur T , le nombre de séquences cachées possibles est de N^T , ce qui rend le calcul direct d'une complexité exponentielle si on l'effectue de manière naïve.

La solution optimale est d'utiliser l'algorithme de forward qui permet de calculer $\mathbb{P}(Y)$ avec une complexité de $O(N^2T)$.

Cet algorithme repose sur le concept de programmation dynamique et utilise une variable intermédiaire $\alpha_t(i)$ qui représente la probabilité d'observer la séquence d'observation $Y_1 \dots Y_t$ et d'être dans l'état caché i à l'instant t .

Formellement, on définit $\alpha_t(i)$ comme :

$$\alpha_t(i) = \mathbb{P}(Y_1, \dots, Y_t, X_t = i).$$

Forward Algorithm :

1) Initialisation :

$$\alpha_1(i) = \pi_i b_i(Y_1), \quad \text{pour } i = 1, \dots, N.$$

2) Récursion :

$$\alpha_t(j) = \sum_{i=1}^N \alpha_{t-1}(i) a_{ij} b_j(Y_t), \quad \text{pour } t = 1, \dots, T \text{ et } j = 1, \dots, N.$$


3) Terminaison :

$$\mathbb{P}(Y) = \sum_{i=1}^N \alpha_T(i).$$

avec a_{ij} la probabilité de transition de l'état i à l'état j , $b_j(Y_t)$ la probabilité d'observer Y_t conditionnellement à être dans l'état j à l'instant t , et π_i la probabilité initiale d'être dans l'état i .

L'algorithme de forward permet ainsi de calculer efficacement la vraisemblance d'une séquence d'observations donnée, en évitant le calcul direct de toutes les séquences d'états cachés possibles.

Pour plus de clareté, on peut présenter l'algorithme de forward sous forme de treillis :



Dans cet exemple, le nombre d'états cachés est de 2 et la longueur de la séquence d'observations est de 3.