

Chaîne de Markov cachées et application en finance

Sous la supervision de *Joseph Rynkiewicz et Jean-Marc Bardet*.

Par Marius Requillart et Maxime Delpech.

2025–2026

SOMMAIRE

I) Définition et propriétés

- 1) Définition d'une chaîne de Markov.
- 2) Définition chaîne de markov cachées.

II) Trois grandes problématiques des HMM

- 1) Estimation de la vraisemblance et forward algorithm.
- 2) Decodding et Viterbi algorithm.
- c) Learning et Baum–Welch algorithm.

III) Application aux séries temporelles financières

Introduction

I) Définitions et propriétés

1) Définition d'une chaîne de Markov

2) Définition d'une chaîne de Markov cachée

Les chaînes de Markov cachées (HMM) sont des modèles statistiques utilisées dans une situation où on a des états latents qui ne sont pas directement observables. Les données observables sont générées par ces états suivant une loi de probabilité conditionnelle.

a) Variables aléatoires observables et cachées

Définition. Les états cachés sont modélisés par un processus de Markov $(X_t)_{t \in \mathbb{N}}$ à valeurs dans un ensemble fini $Q = \{1, \dots, N\}$. On note $A = (a_{ij})$ la matrice de transition définie par :

$$a_{ij} = \mathbb{P}(X_{t+1} = j \mid X_t = i).$$

Définition. Les observations sont modélisées par un processus $(Y_t)_{t \in \mathbb{N}}$ à valeurs dans un ensemble O . Conditionnellement aux états cachés, les variables (Y_t) sont indépendantes et vérifient :

$$\mathbb{P}(Y_t = y \mid X_t = i) = b_i(y),$$

où $B = (b_i(y))$ est la matrice (ou famille) d'émission.

Définition. Un modèle de chaîne de Markov cachée est défini par le triplet (A, B, π) où :

- A est la matrice de transition des états cachés,
- B est la loi d'émission des observations,
- π est la distribution initiale, avec $\pi_i = \mathbb{P}(X_1 = i)$.

b) Loi jointes et vraisemblance

Propriété : Soit $X = (X_1, \dots, X_T)$ la séquence d'états cachés et $Y = (Y_1, \dots, Y_T)$ la séquence d'observations, la loi des observations conditionnellement à la séquence d'états cachés est :

$$\mathbb{P}(Y \mid X) = \prod_{t=1}^T \mathbb{P}(Y_t \mid X_t)$$

Preuve :

$$\mathbb{P}(Y | X) = \prod_{t=1}^T \mathbb{P}(Y_t | X_1, \dots, X_T, Y_1, \dots, Y_{t-1}) = \prod_{t=1}^T \mathbb{P}(Y_t | X_t)$$

Propriété : Soit $X = (X_1, \dots, X_T)$ la séquence d'états cachés et $Y = (Y_1, \dots, Y_T)$ la séquence d'observations, la loi jointes des observations et des états cachés est donnée par :

$$\mathbb{P}(Y, X) = \pi_{X_1} \prod_{t=2}^T \mathbb{P}(X_t | X_{t-1}) \prod_{t=1}^T \mathbb{P}(Y_t | X_t)$$

Preuve :

$$\begin{aligned} \mathbb{P}(X, Y) &= \mathbb{P}(X_1, Y_1) \prod_{t=2}^T \mathbb{P}(X_t, Y_t | X_1, \dots, X_{t-1}, Y_1, \dots, Y_{t-2}) \\ &= \mathbb{P}(X_1) \mathbb{P}(Y_1 | X_1) \prod_{t=2}^T \mathbb{P}(X_t | X_1, \dots, X_{t-1}, Y_1, \dots, Y_{t-2}) \mathbb{P}(Y_t | X_1, \dots, X_{t-1}, Y_1, \dots, Y_{t-2}) \\ &= \mathbb{P}(X_1) \mathbb{P}(Y_1 | X_1) \prod_{t=2}^T \mathbb{P}(X_t | X_{t-1}) \mathbb{P}(Y_t | X_t) \\ &= \mathbb{P}(X_1) \prod_{t=2}^T \mathbb{P}(X_t | X_{t-1}) \prod_{t=1}^T \mathbb{P}(Y_t | X_t) \\ &= \pi_{X_1} \prod_{t=2}^T \mathbb{P}(X_t | X_{t-1}) \prod_{t=1}^T \mathbb{P}(Y_t | X_t) \end{aligned}$$

Remarque : La loi des observations à chaque instant t est dépend de l'état caché à cet instant et pas des états d'avant.

Exemple : Soit un modèle de chaîne de Markov cachée avec deux états A et B . En supposant que les observation sont gaussienne conditionnellement à l'état caché, on a :

$$\mathbb{P}(Y_t | X_t = A) \sim \mathcal{N}(\mu_A, \sigma_A^2)$$

$$\mathbb{P}(Y_t | X_t = B) \sim \mathcal{N}(\mu_B, \sigma_B^2)$$

Remarque : X_t agit comme un selecteur de distribution pour Y_t .

c) Exemple de globale d'une chaîne de Markov cachée

Prenons un exemple simple d'une chaîne de Markov cachée avec deux états C et V (pour "calme" et "volatile") et des observations gaussiennes conditionnelles à ces états.

Soit $E = \{C, V\}$ l'ensemble d'états, on note π la distribution initiale, par exemple $\pi_0 = (0.5, 0.5)$, indiquant que le processus commence avec une probabilité égale dans les états C et V .

La matrice de transition A peut être définie comme suit :

$$A = \begin{pmatrix} 0.9 & 0.1 \\ 0.2 & 0.8 \end{pmatrix}$$

Avec, $a_{ij} = \mathbb{P}(X_{t+1} = j \mid X_t = i)$.

La matrice d'émission B peut être définie par les distributions gaussiennes conditionnelles à chaque état :

$$B = \begin{cases} \mathbb{P}(Y_t \mid X_t = C) \sim \mathcal{N}(\mu_C, \sigma_C^2) \\ \mathbb{P}(Y_t \mid X_t = V) \sim \mathcal{N}(\mu_V, \sigma_V^2) \end{cases}$$

NB : La matrice de transition A n'est pas connue dans la plupart des applications, elle doit être estimée à partir des données d'observations. Par exemple avec l'algorithme de Baum-Welch que nous verrons plus tard.




FIGURE 1 – Modèle de Markov caché (HMM)

d) Remarque sur les observations

Propriété : La probabilité totale des observation Y_T est donnée par :

$$\mathbb{P}(Y) = \sum_X \mathbb{P}(Y, X) = \sum \mathbb{P}(Y | X) \mathbb{P}(X)$$

Propriété : Dans un HMM les observations (Y_t) n'est pas un processus de Markov, même si les états cachés (X_t) le sont.

Preuve :

Si le processus d'observations (Y_t) était markovien. Alors on aurait

$$\mathbb{P}(Y_{n+1} | Y_1, \dots, Y_n) = \mathbb{P}(Y_{n+1} | Y_n).$$

Or, pour K états cachés, on a

$$\begin{aligned} \mathbb{P}(Y_{n+1} | Y_1, \dots, Y_n) &= \sum_{i=1}^K \mathbb{P}(Y_{n+1}, X_{n+1} = i | Y_1, \dots, Y_n) \\ &= \sum_{i=1}^K \mathbb{P}(Y_{n+1} | X_{n+1} = i, Y_1, \dots, Y_n) \mathbb{P}(X_{n+1} = i | Y_1, \dots, Y_n) \\ &= \sum_{i=1}^K \mathbb{P}(Y_{n+1} | X_{n+1} = i) \mathbb{P}(X_{n+1} = i | Y_1, \dots, Y_n). \end{aligned}$$

Ainsi, le terme

$$\mathbb{P}(X_{n+1} = i | Y_1, \dots, Y_n)$$

dépend en général de tout le passé observé $(Y_1, \dots, Y_n)$, et pas seulement de Y_n .

Donc, en général,

$$\mathbb{P}(Y_{n+1} | Y_1, \dots, Y_n) \neq \mathbb{P}(Y_{n+1} | Y_n),$$

ce qui montre que le processus d'observations (Y_t) n'est pas markovien.